

Prediksi Mortalitas dengan Metode Artificial Neural Network

¹Dwight J.O Hutagalung, ²Georgius Diko Parulian, ³M Adli Rahmat Solihin, ⁴M Alanna Daffa R.

¹²³⁴⁵Program Studi S1 Ilmu Aktuaria, Universitas Indonesia

¹²³⁴⁵Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Indonesia

¹²³⁴⁵Jl. Prof. DR. Sudjono D. Puspongoro, Universitas Indonesia, Pondok Cina, 16425

e-mail:

¹dwight.johutagalung@ui.ac.id

²georgius.diko@ui.ac.id

³muhammad.adli01@ui.ac.id

⁴muhammad.alanna@ui.ac.id

Correspondence cell phone number: ¹081318809590, ²082111610296, ³081385325445,
⁴082169110155

ABSTRACT

Perubahan zaman dan kompleksitas faktor-faktor yang memengaruhi tingkat kematian manusia menuntut pendekatan baru dalam prediksi mortalitas. Artikel ini membahas pentingnya penggunaan Artificial Neural Network (ANN) dalam pemodelan mortalitas sebagai upaya untuk meningkatkan akurasi prediksi dan manajemen risiko kesehatan. Dalam konteks perubahan dinamis, penggunaan teknologi canggih seperti ANN memberikan peluang untuk menggabungkan variabel klinis dan demografis, memberikan wawasan mendalam tentang faktor-faktor yang mempengaruhi mortalitas. Penelitian ini tidak hanya berfokus pada statistik semata, melainkan pada informasi mendalam yang dapat mendukung perencanaan intervensi kesehatan yang lebih personal dan tepat waktu.

Artikel ini melakukan peninjauan literatur terkait pemodelan mortalitas, menyoroti berbagai metode machine learning seperti Decision Tree, Gradient Boosting, dan Random Forest yang telah diaplikasikan pada penelitian sebelumnya. Lebih lanjut, artikel membahas model-model terkini, seperti Light GBM, Regression Tree Boosting, dan Deep Neural Network (DNN), yang menunjukkan hasil yang menjanjikan dalam memprediksi mortalitas. Melalui analisis kritis terhadap literatur, artikel ini membuktikan bahwa penggunaan ANN, sebagai representasi dari model Deep Learning, memberikan kontribusi signifikan dalam meningkatkan akurasi prediksi mortalitas.

Metodologi penelitian disusun dengan menguraikan penggunaan data dari sumber Kaggle, langkah-langkah pre-processing data, dan pembagian data untuk melatih dan menguji model ANN. Evaluasi model dilakukan melalui beberapa metrik, termasuk akurasi, presisi, recall, F1-score, dan AUC-ROC. Hasil evaluasi tersebut memberikan gambaran kinerja model ANN, yang memiliki akurasi sebesar 77%, presisi 84%, recall 89%, F1-score 86%, dan AUC-ROC 63%. Penelitian ini memberikan kontribusi penting dalam meningkatkan pemahaman tentang penerapan ANN dalam prediksi mortalitas, dengan implikasi signifikan untuk pengelolaan risiko kesehatan dan pengambilan keputusan medis.

Kata Kunci: Mortalitas; Artificial Neural Network (ANN); Prediksi; Klasifikasi

A. LATAR BELAKANG

Perubahan zaman yang tidak terhindarkan, meninggalkan manusia pada suatu ketidakpastian. Teknologi yang terus berubah, gaya hidup yang kian bervariasi, membuat manusia terus hidup dalam ketidakpastian. Salah satu hal yang terpengaruh oleh ini adalah tingkat kematian manusia. Tingkat kematian merupakan suatu ukuran yang digunakan untuk menggambarkan jumlah individu yang meninggal dalam suatu populasi selama suatu periode waktu tertentu. Tentunya, tingkat kematian manusia di zaman sekarang, akan berubah dengan gaya hidup yang berbeda, dan kondisi lingkungan yang berubah. Dengan metode prediksi tingkat kematian sekarang, tentunya akan cukup sulit untuk menemukan hasil yang akurat, dikarenakan data historis yang sudah tidak relevan dengan keadaan sekarang, padahal tingkat kematian adalah salah satu indikator penting dalam epidemiologi, statistik kesehatan, demografi, dan ilmu sosial.

Dalam era perubahan dinamis inilah, prediksi mortalitas dengan menggunakan *Artificial Neural Network* (ANN) telah menjadi fokus utama penelitian untuk meningkatkan pemahaman dan manajemen risiko kesehatan. Mortalitas, atau tingkat kematian, bukan hanya menjadi indikator kesehatan populasi, tetapi juga merupakan elemen integral dalam pengambilan keputusan medis yang berkualitas. Dalam kerangka ini, penggunaan teknologi canggih seperti ANN memberikan peluang baru untuk meningkatkan akurasi prediksi dan, oleh karena itu, meningkatkan efektivitas sistem kesehatan secara keseluruhan.

Pentingnya penelitian ini tidak dapat diabaikan. Dengan menerapkan model *Deep Learning* seperti ANN, kita dapat lebih efektif menggabungkan berbagai variabel klinis dan demografis, memungkinkan kita untuk mendapatkan wawasan mendalam tentang faktor-faktor yang mempengaruhi mortalitas. Ini bukan hanya sekadar statistik, tetapi serangkaian informasi yang dapat membantu dalam merencanakan intervensi kesehatan yang lebih personal dan tepat waktu.

Hasil penelitian ini memiliki dampak yang signifikan dalam beberapa bidang. Pertama-tama, peningkatan akurasi prediksi dapat membantu penyedia layanan kesehatan merencanakan alokasi sumber daya secara lebih efisien. Dengan memahami risiko kematian pada tingkat individu, kita dapat lebih baik mempersonalisasi perawatan, memastikan bahwa setiap pasien menerima perhatian yang sesuai dengan kebutuhannya.

Selain itu, penerapan ANN dalam sistem pendukung keputusan klinis membuka pintu bagi perbaikan besar dalam pengambilan keputusan medis. Dokter dan profesional kesehatan dapat mengakses informasi yang lebih akurat dan relevan, membantu mengurangi kesalahan diagnostik dan meningkatkan efisiensi dalam memberikan perawatan.

B. PENINJAUAN LITERATUR

Pemodelan Mortalitas

Model mortalitas adalah alat analisis statistik atau matematika yang digunakan untuk menggambarkan hubungan antara faktor-faktor yang berkontribusi terhadap tingkat kematian dalam suatu populasi. Model ini dapat berupa persamaan matematika atau rumusan statistik yang menghubungkan variabel-variabel seperti usia, jenis kelamin, faktor-faktor kesehatan, dan

faktor-faktor risiko lainnya dengan tingkat kematian. Tujuannya adalah untuk mengidentifikasi pola mortalitas, memahami tren, dan memprediksi bagaimana tingkat kematian akan berubah di masa depan. Model mortalitas digunakan dalam berbagai bidang, termasuk asuransi, demografi, epidemiologi, dan penelitian kesehatan, untuk membantu dalam perencanaan, pengambilan keputusan, dan analisis risiko. Model mortalitas bisa sangat sederhana, seperti model regresi linier yang menghubungkan usia dengan tingkat kematian, atau bisa lebih kompleks, seperti model mortalitas Lee-Carter atau model Cairns-Blake-Dowd yang memanfaatkan teknik statistik yang lebih canggih untuk menggambarkan pola mortalitas. Pilihan model akan bergantung pada data yang tersedia dan tujuan penelitian.

Perkembangan Saat Ini

Levantesi dan Pizzorusso (2019) mengaplikasikan *machine learning* untuk membantu dalam pemodelan mortalitas dengan menggunakan *Decision Tree*, *Gradient Boosting*, dan *Random Forest*. *Random Forest* ditemukan menjadi yang paling baik dan efektif dalam pemodelan mortalitas yang digunakan untuk meningkatkan kualitas fitting pada model Lee-Carter, Renshaw-Haberman dan Plat pada populasi Italia. Metode *Random Forest* dapat menurunkan MAPE tertinggi yang dicapai oleh model Plat dengan penurunan dari 25,81% menjadi 4,79% setelah penerapan algoritma *Random Forest* (dari 22,34% menjadi 4,49% untuk populasi perempuan).

Kemudian, Light GBM menjadi model yang paling unggul dalam memprediksi kematian pasien sepsis (Bao, C., dkk. 2023). Light GBM mencapai rata-rata *f1-score* 0.909483 pada *training model* dan 0.905742 saat *testing*. Pencapaian tersebut mengungguli metode lain, seperti *XGBoost*, *Multiple Layer Perception* (MLP), *Gradient Boosting Machine* (GBM), *Random Forest*, *Decision Tree*, dan *Support Vector Machine* (SVM). Penelitian ini juga mendapati SVM sebagai model dengan *f1-score* paling rendah.

Regression Tree Boosting juga menjadi metode *machine learning* yang dapat digunakan untuk pemodelan mortalitas. Deprez, dkk (2017) menggunakan salah satu metode *machine learning*, yaitu *Regression Tree Boosting* untuk menganalisis kekurangan pada model Lee-Carter dan Renshaw-Haberman (salah satu pengembangan dari model Lee-Carter). Selain untuk mendeteksi kekurangan suatu model, *Regression Tree Boosting* dapat meningkatkan *fitness* dari suatu model. Metode ini menawarkan cara yang sederhana untuk dapat mendeteksi pola dari suatu probabilitas dari waktu ke waktu.

Selain itu salah satu model *Deep Learning*, yaitu DNN juga pernah digunakan untuk memprediksi mortalitas selama tindak lanjut klinis 1 tahun setelah keluar dari rumah sakit pada pasien ACS di Korea oleh Sherazi, dkk (2020). Performa *Precision* DNN mampu mengungguli model *machine learning* seperti GBM, GLM, *Random Forest*, serta model regresi seperti GRACE. Namun, performa GBM lebih baik pada AUC, *Recall*, *Accuracy*, dan *F-score* dibandingkan dengan metode lainnya. Walaupun performa AUC GBM dan DNN sama, GBM secara general terbaik dalam memprediksi mortalitas.

Model *Artificial Neural Network*

Artificial Neural Network (ANN), biasanya disebut Jaringan Saraf (NN), adalah suatu algoritma yang pembentukannya dimotivasi agar dapat mengkonstruksi suatu mesin yang dapat meniru sistem jaringan otak. Jaringan saraf terdiri dari sekelompok sel-sel buatan yang saling terhubung. Mereka adalah sistem seluler fisik yang mampu memperoleh, menyimpan informasi, dan menggunakan pengetahuan empiris. Seperti otak manusia, pengetahuan ANN berasal dari contoh yang mereka temui. Dalam sistem saraf manusia, proses pembelajaran melibatkan modifikasi pada koneksi sinaptik antara neuron. Dengan cara yang mirip, ANN menyesuaikan strukturnya berdasarkan informasi keluar dan masuk yang mengalir melalui jaringan selama fase pembelajaran.

Prosedur pemrosesan data dalam jaringan saraf umumnya memiliki dua langkah utama: pembelajaran dan aplikasi. Pada langkah pertama, diperlukan basis data pelatihan atau data harga historis untuk melatih jaringan. Dataset ini mencakup vektor masukan dan vektor keluaran yang diketahui. Setiap masukan dan keluaran mewakili suatu simpul atau neuron. Selain itu, terdapat satu atau lebih lapisan tersembunyi. Tujuan dari fase pembelajaran adalah menyesuaikan bobot koneksi antar lapisan atau simpul. Setelah menyiapkan sampel pembelajaran, dalam pendekatan berulang, sampel akan dimasukkan ke dalam jaringan dan hasil keluarannya akan dibandingkan dengan keluaran yang diketahui. Jika hasilnya dan keluaran yang tidak diketahui tidak sama, perubahan bobot koneksi akan terus dilakukan hingga perbedaan diminimalkan. Setelah mencapai konvergensi yang diinginkan untuk jaringan dalam proses pembelajaran, dataset validasi diterapkan pada jaringan untuk langkah validasi (Shahkarami A. et al. 2014).

C. METODOLOGI

Data

Data yang digunakan dalam penelitian ini disunting dari laman <https://www.kaggle.com/code/laurencegesman/hospital-mortality-ml-data-analysis/input> yang diunggah oleh akun Laurence Gesman. Data yang digunakan merupakan data berbentuk .csv dengan total jumlah data sebanyak 60087 entri data dengan rincian sebanyak 1178 baris dan 51 kolom. Data ini berisikan informasi terkait rekam jejak medis dari sekumpulan pasien yang berada di rumah sakit yang diamati kondisi kesehatannya secara menyeluruh serta diamati juga apakah pasien tersebut meninggal atau tidak selama dirawat pada rumah sakit tersebut. Data yang digunakan berisikan 39 variabel numerik serta 12 variabel kategorik dengan rincian 50 variabel digunakan sebagai variabel prediktor dan 1 variabel kategorik digunakan sebagai variabel target yaitu variabel outcome yang menjelaskan status kehidupan pasien, apakah pasien tersebut masih hidup atau sudah meninggal dunia.

Pre-Processing Data

Pre-processing data adalah serangkaian langkah atau teknik yang dilakukan pada data sebelum data tersebut digunakan sebagai input untuk model atau analisis lebih lanjut. Tujuan dari pre-processing data adalah untuk mempersiapkan dan membersihkan data sehingga dapat diolah dengan benar oleh algoritma atau model *Artificial Neural Network*. Beberapa langkah pre-processing data yang dilakukan dalam penelitian ini meliputi *data imputing*, *data splitting*, dan standarisasi data.

1. Impute Data

Imputasi adalah pilihan penanganan missing data yang paling bijak dari pada membuang sebagian observasi atau variabel yang mengandung missing value, mengingat bahwa data sangat mahal dan berharga. Di bagian *pre-processing* ini, peneliti memanfaatkan `sklearn.impute` untuk mengisi variabel dengan *missing value* agar dapat digunakan dalam pembentukan model.

2. Standarisasi Data

Tujuan utama dari melakukan standarisasi adalah untuk menurunkan semua fitur ke skala yang sama tanpa mendistorsi perbedaan dalam rentang nilai. Dengan beragamnya skala numerik yang dimiliki dari puluhan variabel yang ada, perlu dilakukan standarisasi data untuk mendukung proses pembentukan model. Dalam pengerjaannya, peneliti menggunakan `sklearn.preprocessing` dan melakukan *import* terhadap fitur `MinMaxScaler` dan juga `StandardScaler`.

3. Data Splitting

Data splitting adalah metode membagi data menjadi dua bagian atau lebih yang membentuk subhimpunan data. Umumnya, data splitting memisahkan dua bagian, bagian pertama digunakan untuk mengevaluasi atau uji data dan data lainnya digunakan untuk melatih model. Dalam pembentukan model *deep learning* nantinya, data yang dimiliki dibagi menjadi data training dan testing, dengan komposisi 80% digunakan sebagai *data training*, 10% digunakan sebagai *data validation*, dan 10% sisanya digunakan sebagai *data testing*.

Evaluasi Model

Evaluasi model yang didapatkan nantinya akan dibandingkan dari tiga indikator, yaitu akurasi yang didapat dari *loss function*, *evaluation metrics*, dan juga metode ROC-AUC.

1. Loss Function

Loss function (fungsi kerugian) adalah suatu metrik yang digunakan dalam pembelajaran mesin dan deep learning untuk mengukur seberapa baik model memprediksi nilai target. Loss function mengukur seberapa jauh hasil prediksi model dari nilai sebenarnya yang diinginkan. Dalam konteks deep learning dan khususnya pada tugas klasifikasi biner

(binary classification), Binary Crossentropy adalah salah satu jenis fungsi kerugian yang umum digunakan.

Binary Crossentropy, atau sering disebut Logarithmic Loss, digunakan ketika tugas klasifikasi bersifat biner, artinya terdapat dua kelas yang mungkin untuk setiap sampel (biasanya kelas positif dan negatif). Fungsi ini membandingkan distribusi probabilitas yang dihasilkan oleh model dengan distribusi probabilitas yang sebenarnya dari kelas target.

2. Evaluation Metrics

Evaluation Metrics atau metrik evaluasi digunakan untuk mengevaluasi model setelah dilakukan tahapan data *training*. Metrik ini mengukur seberapa baik model dapat melakukan generalisasi pada data baru dan membuat prediksi yang akurat. Metrik evaluasi juga membandingkan berbagai model atau konfigurasi untuk menentukan yang paling baik dalam kinerjanya.

Properti atau karakteristik dari metrik evaluasi, yang digunakan untuk menilai kinerja model, melibatkan:

1. Akurasi: Mengukur kebenaran keseluruhan prediksi model, dihitung sebagai rasio prediksi yang benar terhadap total prediksi.
2. Presisi: Menunjukkan akurasi prediksi positif, dihitung sebagai rasio prediksi positif benar terhadap jumlah prediksi positif benar dan prediksi positif salah.
3. Recall : Mengukur kemampuan model untuk menangkap semua instansi positif, dihitung sebagai rasio prediksi positif benar terhadap jumlah prediksi positif benar dan prediksi negatif salah.
4. Skor F1: Mean harmonik dari presisi dan recall, memberikan ukuran seimbang yang mempertimbangkan baik prediksi positif salah maupun prediksi negatif salah.
5. Spesifisitas :Mengukur kemampuan model untuk mengidentifikasi instansi negatif dengan benar, dihitung sebagai rasio prediksi negatif benar terhadap jumlah prediksi negatif benar dan prediksi positif salah.
6. Matriks Konfusi (Confusion Matrix): Tabel yang merangkum kinerja model dengan memecah prediksi menjadi positif benar, negatif benar, positif salah, dan negatif salah.

3. ROC-AUC

Area Under the Receiver Operating Characteristic Curve (AUC-ROC) adalah metrik evaluasi yang umum digunakan dalam konteks klasifikasi biner untuk mengukur sejauh mana model mampu membedakan antara dua kelas. Mari kita bahas penjelasannya:

1. Receiver Operating Characteristic (ROC) Curve: ROC Curve adalah sebuah grafik yang menggambarkan kinerja model klasifikasi pada berbagai ambang batas (threshold) untuk membedakan antara kelas positif dan negatif. Pada sumbu X, ROC Curve menunjukkan tingkat positif palsu (False Positive Rate), sedangkan pada sumbu Y, ia menunjukkan tingkat positif benar (True Positive Rate atau Sensitivity). Setiap titik pada kurva mewakili suatu ambang batas tertentu.
2. True Positive Rate (Sensitivity): Merupakan proporsi positif benar yang diidentifikasi oleh model dari seluruh jumlah kasus positif sebenarnya. Diukur sebagai rasio True Positive (TP) dibagi dengan jumlah keseluruhan positif sebenarnya.

$$Sensitivity = \frac{TP}{TP+FN}$$

3. False Positive Rate (1-Specificity): Merupakan proporsi negatif sebenarnya yang salah diidentifikasi sebagai positif oleh model dari seluruh jumlah kasus negatif sebenarnya. Diukur sebagai rasio False Positive (FP) dibagi dengan jumlah keseluruhan negatif sebenarnya.

$$False\ Positive\ Rate = \frac{FP}{TN+FP}$$

4. Area Under the Curve (AUC): AUC adalah luasan di bawah kurva ROC. Ini memberikan ukuran singkat tentang seberapa baik model mampu membedakan antara kelas positif dan negatif. Nilai AUC berkisar antara 0 dan 1, di mana nilai 1 menunjukkan model yang sempurna (memiliki sensitivitas 100% dan spesifisitas 100%), sementara nilai 0.5 menunjukkan kinerja model yang sama seperti acak.

Semakin tinggi nilai AUC, semakin baik modelnya dalam membedakan antara kedua kelas. Jika AUC berada di sekitar 0.5, ini menunjukkan bahwa model tidak lebih baik daripada model yang memprediksi secara acak.


AUC-ROC memberikan pandangan menyeluruh tentang performa model klasifikasi di berbagai ambang batas dan sangat berguna terutama ketika keseimbangan antara sensitivitas dan spesifisitas perlu dipertimbangkan. Semakin dekat nilai AUC-ROC

dengan 1, semakin baik kemampuan model dalam membedakan antara kelas positif dan negatif.

D. HASIL DAN DISKUSI

Hasil kinerja dari model yang dibangun dievaluasi dengan metrik seperti *accuracy* untuk melihat kinerja model secara umum dalam mengklasifikasikan setiap kelas. Namun, kinerja model perlu ditinjau lebih lanjut untuk dapat menilai bagaimana model klasifikasi bekerja sesuai tujuan dari penelitian ini. Tujuan dari pembangunan model dilakukan untuk dapat memprediksi kelas positif atau yang menjadi nilai minoritas dari data, yaitu variabel target ‘outcome’ bernilai 1 yang mengindikasikan kematian pasien. Analisis kinerja model dalam mengklasifikasi secara spesifik dapat dilakukan dengan memanfaatkan confusion matrix yang memberikan nilai-nilai untuk dapat melihat metrik seperti *accuracy*, *precision*, *recall*, *f1-score*, *AUC-ROC*.

Berikut merupakan *confusion matrix* yang didapatkan dari hasil pada *testing* model ANN yang dibangun.



Gambar 1. Confusion Matrix Model ANN

Dari confusion matrix tersebut, dapat dilihat bahwa nilai dari masing-masing entri , yaitu

- TN = 86, sebanyak 86 sampel negatif diprediksi sebagai kelas negatif
- FN = 16, sebanyak 16 sampel negatif diprediksi sebagai kelas positif
- FP = 10, sebanyak 10 sampel positif diprediksi sebagai kelas negatif
- TP = 6, sebanyak 6 sampel positif diprediksi sebagai kelas positif

Selanjutnya, dari nilai-nilai tersebut digunakan untuk menghitung *metrics* yang dapat digunakan untuk meninjau kinerja model ANN yang telah dibangun dalam melakukan klasifikasi. Hasil perhitungan *metrics* tersebut dituliskan pada tabel berikut.

Tabel 1. Reasons for visiting the library (10 pt)

<i>Evaluation Metrics</i>	<i>Value percentage(%)</i>
<i>Accuracy</i>	77%
<i>Precision</i>	84%
<i>Recall</i>	89%
<i>F1-score</i>	86%
<i>AUC-ROC</i>	63%

E. KESIMPULAN

Dalam menghadapi ketidakpastian yang dihadapi manusia akibat perubahan zaman, penelitian ini mengungkap pentingnya prediksi tingkat kematian manusia dengan memanfaatkan teknologi Artificial Neural Network (ANN). Perubahan gaya hidup dan lingkungan menuntut pendekatan yang inovatif untuk memahami dan mengelola risiko kesehatan, dan ANN memberikan solusi yang menjanjikan. Melalui tinjauan literatur, artikel ini mengeksplorasi berbagai model mortalitas yang digunakan dalam berbagai konteks, dari asuransi hingga epidemiologi. Perkembangan saat ini, seperti penerapan machine learning dan deep learning, terbukti mampu meningkatkan akurasi prediksi mortalitas.

Penelitian ini mencatat bahwa penggunaan model ANN dalam pemodelan mortalitas dapat memberikan dampak positif dalam beberapa bidang. Peningkatan akurasi prediksi memberikan peluang bagi penyedia layanan kesehatan untuk mengalokasikan sumber daya secara efisien dan mempersonalisasi perawatan. Penggunaan ANN dalam sistem pendukung keputusan klinis juga membuka pintu bagi perbaikan besar dalam pengambilan keputusan medis, membantu mengurangi kesalahan diagnostik dan meningkatkan efisiensi perawatan.

Melalui metodologi yang terinci, artikel ini menggunakan data dari sumber terpercaya dan melakukan pre-processing data untuk memastikan kehandalan model ANN yang dibangun. Evaluasi model dilakukan dengan mempertimbangkan berbagai metrik, termasuk akurasi, presisi, recall, f1-score, dan AUC-ROC. Hasil evaluasi model menunjukkan bahwa model ANN mampu memberikan kinerja yang baik dalam mengklasifikasikan kelas positif, yang dalam konteks ini merupakan pasien dengan status kematian. Dengan akurasi sebesar 77%, presisi 84%, recall 89%, f1-score 86%, dan AUC-ROC 63%, model ini memberikan wawasan yang berharga dalam merencanakan intervensi kesehatan yang lebih personal dan tepat waktu.

Secara keseluruhan, penelitian ini menegaskan bahwa penggunaan teknologi canggih seperti ANN dalam pemodelan mortalitas adalah langkah yang relevan dan bermanfaat. Dengan pemahaman yang lebih dalam tentang faktor-faktor yang mempengaruhi mortalitas, kita dapat meningkatkan manajemen risiko kesehatan dan memberikan perawatan yang lebih efektif.

Dengan demikian, artikel ini memberikan kontribusi penting dalam menghadapi tantangan kesehatan di era yang terus berubah ini.

DAFTAR PUSTAKA

- Bao, C., et al. "Machine-Learning Models for Prediction of Sepsis Patients Mortality." *Medicina Intensiva (English Edition)*, vol. 47, no. 6, Nov. 2022, <https://doi.org/10.1016/j.medine.2022.06.024>. Accessed 5 Dec. 2022.
- Deprez, Philippe, et al. "Machine Learning Techniques for Mortality Modeling." *European Actuarial Journal*, vol. 7, no. 2, 6 June 2017, pp. 337–352, <https://doi.org/10.1007/s13385-017-0152-4>. Accessed 29 Sept. 2022.
- Levantesi, Susanna, and Virginia Pizzorusso. "Application of Machine Learning to Mortality Modeling and Forecasting." *Risks*, vol. 7, no. 1, 26 Feb. 2019, p. 26, <https://doi.org/10.3390/risks7010026>.
- Sherazi, Syed Waseem Abbas, et al. "A Machine Learning–Based 1-Year Mortality Prediction Model after Hospital Discharge for Clinical Patients with Acute Coronary Syndrome." *Health Informatics Journal*, vol. 26, no. 2, 30 Sept. 2019, pp. 1289–1304, <https://doi.org/10.1177/1460458219871780>. Accessed 24 Dec. 2020.
- Ke, Guolin, et al. *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. 2017.